

## LISTA 3

## Questão 1

a) Gerei cem pontos e plotei os dados na Figura 1A.

b) Adicionei dez por cento do desvio padrão do  $y$  anterior multiplicando à esquerda os randômicos gaussianos (“randn”). Plotei os dados na Figura 1B.

c) A equação de regressão, ponto a ponto, é  $y_i = x^T \theta \Leftrightarrow y_i = \theta_3 x_i^2 + \theta_2 x_i + \theta_1$ .

d) Portanto, precisamos da pseudoinversa de uma **matriz de regressores** de cem linhas cujas colunas são  $[1, x_i, x_i^2]$  vezes um vetor cujas cem linhas são iguais a  $y_i + e_i$ .

e) Os parâmetros encontrados foram  $[-2.468452165780984; 0.716463937117908; 1.529449567129221]$ .

f) Gerei novamente mil pontos, como em (a), e plotei os dados na Figura 2A. Adicionei o erro como em (b) e plotei os dados na Figura 2B. Com nova matriz regressora, os parâmetros encontrados foram  $[-2.019564476840127; 0.702513920204115; 1.507382167796436]$ .

Repare que com dez vezes mais pontos, os parâmetros estimados foram bem mais próximos do ideal  $[-2; 0.7; 1.5]$ . Isso é explicado porque a função objetivo passou a minimizar dez vezes mais realizações de erros:  $J = \sum e_i^2$ .

g) Gerei mais cem pontos, como em (a), e plotei os dados na Figura 3A.

Adicionei dez por cento do desvio padrão do  $x$  anterior multiplicando à esquerda os randômicos gaussianos. Plotei os dados na Figura 3B. Repare que o modo de plotagem precisa ser diferente, uma vez que o vetor  $x$  tornou-se desordenado.

Com nova matriz regressora, os parâmetros encontrados foram

$[-1.715120009257206; 0.501563604178347; 1.440498754963116]$ .

Repare que o resultado foi o menos preciso.

A comparação dos  $(x_2, y_2), (x_3, y_3), (x_4, y_4)$  montados após a regressão foi plotada na Figura 4.

Repare que a diferença entre as aproximações é mínima diante do total dos dados.




Figura 1: 100 pontos gerados (a) sem erro (b) com erro na saída.




Figura 2: 1000 pontos gerados (a) sem erro (b) com erro na saída.





Figura 3: 100 pontos gerados (a) sem erro (b) com erro na entrada.

Figura 4: comparação utilizando os 3 vetores  $\theta$  de parâmetros encontrados.

## Questão 2

a) A entrada é  $prbs(n, 12, 1)$ , subtraída a média, multiplicada por 2, plotada na Figura 5A.

O ruído  $\nu$  (plotado na Figura 5B) são os gaussianos “randn” multiplicados por  $\sqrt{0.1}$ . Vou explicar essa constante.

Pela definição de variância, se nós tivermos  $var(X) = E[X^2] - E^2[X] = v$

$\Rightarrow E[X^2] = v + c^2$ , então ao multiplicarmos por uma constante  $k$ ,

$$var(kX) = E[k^2 X^2] - E^2[kX] = w \Rightarrow k^2 \underbrace{E[X^2]}_{v+c^2} - (ck)^2 = w.$$

$$\therefore k = \pm \sqrt{\frac{w}{v}} \text{ é a constante desejada.}$$

b) Modelo ARX (plotado na Figura 6A):

$$Ay = Bu + \nu$$

$$y(k) = -\theta(1)y(k-1) - \theta(2)y(k-2) + \theta(3)u(k-1) + \theta(4)u(k-2) + \nu(k).$$

c) Modelo ARMAX (plotado na Figura 6B):

$$Ay = Bu + C\nu ; \text{ Repare que troquei } A, B, C \text{ por } \theta, \text{ para futura estimação.}$$

$$y(k) = -\theta(1)y(k-1) - \theta(2)y(k-2) + \theta(3)u(k-1) + \theta(4)u(k-2) + \theta(5)\nu(k) + \theta(6)\nu(k-1).$$

d) Modelo com erro na saída (plotado na Figura 7):

$$Fw = Bu ; y = w + \nu ; \text{ Repare que é o único sem filtro. Não há função de } q \text{ multiplicando } \nu.$$

$$w(k) = -\theta(1)w(k-1) - \theta(2)w(k-2) + \theta(3)u(k-1) + \theta(4)u(k-2) ; y(k) = w(k) + \nu(k).$$




Figura 5: (a) entrada (b) ruído.




Figura 6: Simulações: (a) ARX (b) ARMAX.




Figura 7: Simulação com erro na saída.

### Questão 3

Os parâmetros ideais são  $[-1.5; 0.7; 1; 0.5; 1; 0.8]$ . Veremos que não é possível estimar os dois últimos.

a) ARX: Temos  $y_{(3:1000)} = X\theta$ , em que cada uma das 998 linhas de  $X$  é

$[-y(k-1), -y(k-2), u(k-1), u(k-2)]$ . Os parâmetros encontrados foram:

$[-1.492231811181352; 0.691822104421257; 0.991675629125383; 0.498357708396526]$ .

Foi possível montar toda a matriz de regressão.

b) ARMAX: Não foi possível montar toda a matriz de regressão. Para isso, teríamos que ter disponíveis os dados de  $\nu$ . Os parâmetros encontrados foram:

$[-1.511287691284849; 0.709024279287422; 1.001511280557228; 0.472411376814075]$ .

c) Erro na saída: os parâmetros encontrados foram:

$[-1.428278426942452; 0.632047338684911; 0.973519519942481; 0.582697779355300]$ .

O que acontece aqui é que nós precisaríamos de colunas com os valores de  $w = y - \nu$  que foram trocadas por  $y$ . Portanto, foi possível estimar todos os parâmetros.

d) Sobre o desempenho. Calculando o valor da função objetivo  $J = \sum e_i^2$ , obtivemos

$J_{ARX} = 96.8369$  ;  $J_{ARMAX} = 155.9078$  ;  $J_{ES} = 348.7046$ . Dessa forma, concluímos que a aproximação mais precisa é do ARX, e a menos precisa é a do modelo de erro na saída.

## Questão 4

Por definição,  $J_{reg} = 0.5J_{MQ} + 0.5\lambda\theta^\top\theta$ , em que  $\lambda \in \mathbb{R}$  é um escalar e  $\theta \in \mathbb{R}^n$  é um vetor, a nossa incógnita a ser estimada, minimizando  $J_{reg}$ .

Sejam  $\Psi \in \mathcal{M}_{N \times n}(\mathbb{R})$ ;  $N \geq n$ . Aproximamos a saída pelos parâmetros pré multiplicados pela matriz de regressão, cuja diferença é o erro  $\xi \in \mathbb{R}^n$ .

$$y = \Psi\hat{\theta} + \xi.$$

$$\text{Por definição, } J_{MQ} = \sum_{i=1}^N \xi(i)^2.$$

$$\text{Então, } J_{MQ} = \xi^\top \xi = (y - \Psi\hat{\theta})^\top (y - \Psi\hat{\theta}) = y^\top y - y^\top \Psi\hat{\theta} - \hat{\theta}^\top \Psi^\top y + \hat{\theta}^\top \Psi^\top \Psi \hat{\theta}.$$

$$\text{Derivando, temos que } \frac{\partial J_{reg}}{\partial \hat{\theta}} = 0.5(-\Psi^\top y - \Psi^\top y + 2\Psi^\top \Psi \hat{\theta} + 2\lambda \hat{\theta})$$

O mínimo acontece quando a derivada é zero:

$$\frac{\partial J_{reg}}{\partial \hat{\theta}} = 0 \Rightarrow -\Psi^\top y + \Psi^\top \Psi \hat{\theta} + \lambda \hat{\theta} = 0 \Rightarrow (\Psi^\top \Psi + \lambda I) \hat{\theta} = \Psi^\top y.$$

Finalmente, pré-multiplicando pela inversa dos dois lados:

$$\hat{\theta}_{reg} = [\Psi^\top \Psi + \lambda I]^{-1} \Psi^\top y.$$

O que fizemos foi minimizar  $J_{reg} = \sum_{i=1}^N \xi(i)^2 + \sum_{i=1}^n \theta(i)^2 = \|\xi\|^2 + \|\theta\|^2$ . Essa constante 0.5 é desprezível nesse caso. Portanto, a norma dos parâmetros também será mínima.

Link para os [códigos-fonte](#).

Versão de 13/maio/2022\* por Vinicius Claudino Ferraz.

Matrícula: 2019435823.

---

\*Fora da caridade não há salvação.